

Classification du pays des aéroports avec des réseaux de neurones sur graphes

Sarah KESRAOUI
Maria Sara GHERZOULI

Université Claude Bernard Lyon 1, France

Abstract. This project studies node classification on an airport network using Graph Neural Networks. Each airport is represented by its population and geographical coordinates, while the target is its country. Several models are compared: GCN, GAT, GraphSAGE and an MLP baseline. The ablation study shows that geographical coordinates are the most informative features. The final GAT using only latitude and longitude reaches an average test accuracy of $82.42 \pm 1.22\%$ over five seeds, compared with $80.65 \pm 1.59\%$ for the MLP.

Keywords: Graph Neural Networks, Node Classification, GCN, GAT, GraphSAGE

1 Introduction

Les réseaux de transport aérien peuvent être représentés sous la forme d'un graphe, où les aéroports correspondent aux nœuds et les connexions entre aéroports aux arêtes. Cette représentation permet d'utiliser à la fois les caractéristiques propres aux aéroports et la structure du réseau.

Dans ce projet, la tâche choisie est une classification de nœuds. L'objectif est de prédire le pays d'un aéroport à partir de ses caractéristiques et de ses connexions. La question étudiée est donc : *quelle architecture de réseau de neurones sur graphes est la plus adaptée pour prédire le pays d'un aéroport ?*

Trois architectures de GNN sont comparées : GCN, GAT et GraphSAGE. Un MLP est également utilisé comme baseline sans information sur les arêtes afin d'évaluer l'apport de la structure du graphe.

Le code et les expériences sont disponibles sur le dépôt : <https://github.com/segmentSK9/Projet-GNN->.

2 État de l'art

Les Graph Neural Networks permettent d'apprendre une représentation des nœuds en utilisant leurs caractéristiques et les informations provenant de leur voisinage.

Le Graph Convolutional Network (GCN) proposé par Kipf et Welling [2] met à jour la représentation d'un nœud à partir des informations de ses voisins. Le Graph Attention Network (GAT), proposé par Veličković et al. [3], introduit un mécanisme d'attention qui apprend à donner une importance différente aux voisins. GraphSAGE, proposé par Hamilton et al. [1], repose également sur l'agrégation des représentations voisines ; une agrégation par moyenne est utilisée dans nos expériences.

Enfin, un MLP est utilisé comme baseline sans graphe. Il utilise uniquement les caractéristiques propres aux aéroports et permet donc d'évaluer si les connexions apportent une information supplémentaire.

3 Données et méthodes

3.1 Données et préparation

Le jeu de données est fourni sous la forme d'un fichier GraphML contenant 3363 aéroports et 13547 arêtes. Chaque nœud contient notamment la population de la ville, sa latitude, sa longitude, son pays et le nom de la ville.

La variable à prédire est le pays de l'aéroport. Les caractéristiques initialement utilisées sont la population, la latitude et la longitude. Après encodage des pays, le problème contient 212 classes. Les variables numériques sont standardisées et le graphe NetworkX est converti au format PyTorch Geometric.

Le jeu de données est fortement déséquilibré : certains pays possèdent plusieurs centaines d'aéroports alors que d'autres n'en possèdent qu'un ou quelques-uns. Un découpage tenant compte des classes est utilisé afin que les 212 classes soient représentées dans l'ensemble d'entraînement. Il contient 2310 nœuds d'entraînement, 467 de validation et 586 de test. Les mêmes ensembles sont utilisés pour tous les modèles.

3.2 Modèles

Le **GCN** contient deux couches GCNConv. La première transforme les trois caractéristiques en une représentation de dimension 32, suivie d'une ReLU, et la seconde produit les scores des 212 classes. Le meilleur checkpoint est sélectionné selon l'accuracy de validation.

Le **GAT** contient deux couches GATConv. La première utilise deux têtes d'attention de dimension 32 dont les sorties sont concaténées. La seconde produit les scores des 212 classes.

GraphSAGE contient deux couches SAGEConv et utilise une agrégation par moyenne. La première couche produit une représentation de dimension 32 et la seconde réalise la classification.

Enfin, le **MLP** contient deux couches linéaires avec une couche cachée de dimension 32. Il utilise les mêmes caractéristiques mais aucune arête, ce qui en fait une baseline permettant de mesurer l'intérêt de la structure du graphe.

Tous les modèles sont entraînés avec Adam, un taux d'apprentissage de 0.01 et la Cross-Entropy. Les mêmes ensembles d'entraînement, de validation et de test sont conservés pour assurer une comparaison équitable.

4 Résultats

Le tableau 1 compare les modèles sur une première exécution. Une baseline supplémentaire prédit systématiquement la classe majoritaire.

Modèle	Validation	Test
Classe majoritaire	–	16.89
GCN	79.66	76.96
GraphSAGE	80.30	76.45
GAT	81.37	79.69
MLP	85.22	81.40

TABLE 1 – Accuracy (%) des différents modèles sur une exécution.

Le MLP obtient la meilleure accuracy test sur cette première expérience avec 81.40%, suivi du GAT avec 79.69%. GraphSAGE et le GCN atteignent respectivement 76.45% et 76.96%. Le bon résultat du MLP montre que les caractéristiques des aéroports contiennent déjà beaucoup d’information pour prédire leur pays.

Une analyse des résultats a également montré un effet important du déséquilibre des classes. Les pays possédant peu d’aéroports sont plus difficiles à classer. Pour le GAT, l’accuracy passe de 13.04% pour les pays rares (1 à 5 aéroports) à 69.03% pour les pays intermédiaires et 89.70% pour les pays possédant plus de 20 aéroports.

5 Étude d’ablation

Une étude d’ablation est réalisée sur le GAT afin d’évaluer l’importance des différentes caractéristiques d’entrée. Trois configurations sont comparées : les trois caractéristiques, les coordonnées uniquement et la population uniquement.

Caractéristiques	Test
Population + latitude + longitude	79.69
Latitude + longitude	81.57
Population uniquement	47.61

TABLE 2 – Accuracy test (%) du GAT selon les caractéristiques utilisées.

La suppression de la population améliore l’accuracy de 79.69% à 81.57%. À l’inverse, lorsque seule la population est utilisée, l’accuracy chute à 47.61%. Les coordonnées géographiques sont donc les caractéristiques les plus importantes

pour cette tâche. La population n’apporte pas d’amélioration dans la configuration étudiée.

Pour vérifier que le résultat ne dépend pas d’une seule initialisation, les deux meilleures configurations sont ensuite entraînées avec cinq seeds différentes (0, 1, 2, 3 et 4). Les mêmes masques sont conservés et seule l’initialisation des poids varie.

Modèle	Test (moyenne $\pm$ écart-type)
MLP	80.65 ± 1.59
GAT (latitude + longitude)	82.42 ± 1.22

TABLE 3 – Accuracy test (%) sur cinq seeds.

Même si le MLP obtenait le meilleur résultat lors de la première exécution, le GAT utilisant uniquement la latitude et la longitude obtient la meilleure performance moyenne sur les cinq seeds. Il présente également un écart-type plus faible. Cette configuration est donc retenue comme modèle final.

6 Conclusion

Ce projet a permis de comparer plusieurs architectures pour la classification du pays des aéroports. Les premières expériences montrent que le MLP est une baseline forte, ce qui confirme l’importance des caractéristiques géographiques.

L’étude d’ablation montre que la latitude et la longitude sont suffisantes pour obtenir les meilleures performances du GAT, tandis que la population n’améliore pas les résultats. Sur cinq seeds, le GAT final atteint $82.42 \pm 1.22\%$ d’accuracy test, contre $80.65 \pm 1.59\%$ pour le MLP. La structure du graphe apporte donc une amélioration supplémentaire lorsque les caractéristiques les plus pertinentes sont utilisées.

Références

1. Hamilton, W.L., Ying, R., Leskovec, J. : Inductive representation learning on large graphs. In : Advances in Neural Information Processing Systems. vol. 30 (2017)
2. Kipf, T.N., Welling, M. : Semi-supervised classification with graph convolutional networks. In : International Conference on Learning Representations (ICLR) (2017)
3. Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., Bengio, Y. : Graph attention networks. In : International Conference on Learning Representations (ICLR) (2018)